
Ampliación de Fundamentos de Hardware

Angel Fabrizio Ullaguari Yanza

2°ASIR

Práctica IA. Cuantización



Práctica

Preparación del entorno. Cargamos el modelo original Phi-3-mini-4k-instruct de Microsoft desde Hugging Face.



Ahora probamos el modelo cuantizado.



Aquí se comparan los dos archivos en la lista de modelos. El modelo original Phi 3 Mini F16 (no cuantizado) ocupa más espacio almacenado que el modelo Q4 (cuantizado).

Your Models		Recency ↓		Size	Downloaded	
Phi 3 Mini	F16	lmstudio-community	3B	ph13	GGUF	7.12 GB >
Phi 3 Mini	Q4	lmstudio-community	3B	ph13	GGUF	2.23 GB >

Verificación y Prueba. Esta captura muestra una comparativa de velocidad de generación de texto con ambos modelos. En nuestro caso nos salió al revés, o sea, el modelo no cuantizado nos da la respuesta con menos tokens por segundo cuando debería ser el modelo cuantizado el que dé menos tok/sec.

